

МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
Кафедра МО ЭВМ

ОТЧЕТ
по проекту
по дисциплине «Обучение с подкреплением»
Тема: Реализация и тестирование модификаций DQN

Студент гр. 1303	_____	Жвирблинский Я. В. Симчук А.
Преподаватель	_____	Глазунов С.А.

Санкт-Петербург
2026

Цель работы.

Необходимо реализовать и сравнить между собой версии DQN

Задание.

Необходимо реализовать и сравнить между собой следующие модификации DQN:

1. Prioritized replay
2. Dueling networks
3. Noisy Nets

В качестве окружения для тестирования:

1. LunarLander-v3
2. Mountain-Car

Описание тестовых сред и критериев

LunarLander-v3

Среда LunarLander-v3 представляет собой задачу управления посадочным модулем. Модель должна управлять двигателями аппарата таким образом, чтобы выполнить посадку на площадку между двумя флагами. Среда имеет дискретное пространство действий из четырёх вариантов: ничего не делать, включить левый боковой двигатель, включить основной двигатель или включить правый боковой двигатель.

Награда в среде зависит от положения модуля относительно посадочной площадки, скорости движения, угла наклона, контакта опор с поверхностью, расхода топлива и результата завершения эпизода. За успешную посадку модель получает дополнительную положительную награду, а за падение - штраф. Среда считается решённой, если итоговая награда достигает не менее 200 очков.

Данная среда была выбрана, так как она требует от модели не только выбирать правильное действие в текущем состоянии, но и учитывать долгосрочные последствия этих действий. Например, слишком частое использование двигателя может привести к штрафам, а недостаточное управление скоростью - к падению.

MountainCar-v0

Среда MountainCar-v0 представляет собой задачу, в которой машина находится в долине между двумя холмами и должна достичь вершины правого холма. При этом мощности двигателя недостаточно, чтобы сразу заехать на гору, поэтому модель должна научиться сначала раскачивать машину, набирая скорость за счёт движения в разные стороны.

Состояние среды задаётся двумя величинами: положением машины и её скоростью. Пространство действий дискретное и включает три действия: ускорение влево, отсутствие ускорения и ускорение вправо. Цель состоит в том, чтобы как можно быстрее достичь правой вершины.

Особенность среды состоит в разреженной и отрицательной системе наград: модель получает штраф за каждый шаг, поэтому улучшение качества выражается не в росте награды к большим положительным значениям, а в приближении среднего результата к менее отрицательным значениям. Поэтому для ускорения обучения в коде дополнительно используется модифицированная награда, однако для построения итоговых графиков сохраняется реальная награда среды.

Цель и параметры модели

Целью модели является аппроксимация функции действия-ценности $Q(s,a)$, которая показывает ожидаемую суммарную награду при выборе действия a в состоянии s . На основе полученных Q -значений модель выбирает действие с наибольшей ожидаемой выгодой.

Вариант модели	Описание
Base DQN	Базовая модель DQN с replay buffer и target-сетью
DQN + Prioritized Replay	Модель с приоритизированным буфером опыта
Dueling DQN	Модель с разделением оценки состояния и преимущества действий
Noisy DQN	Модель с шумовыми слоями для улучшения исследования среды

Выполнение работы.

Эксперимент 1. Сравнение модификаций DQN в среде LunarLander-v3

В первом эксперименте проводилось сравнение четырёх вариантов DQN-модели в среде LunarLander-v3: базовой DQN, DQN с Prioritized Replay, Dueling DQN и Noisy DQN. Цель эксперимента состояла в оценке того, как отдельные модификации алгоритма влияют на динамику обучения и итоговое значение средней реальной награды. Обучение каждой модели выполнялось в течение 1000 эпизодов. Для анализа использовалась средняя реальная награда за последние 50 эпизодов, выводимая каждые 50 эпизодов обучения.




Рисунок 1 - Сравнение модификаций DQN в среде LunarLander-v3

Модель	Эпоха 100	Эпоха 300	Эпоха 500	Эпоха 700	Эпоха 900	Эпоха 1000
Base DQN	-103.47	52.45	234.03	224.32	252.41	265.54
DQN + Prioritized Replay	-116.46	-82.52	11.54	163.59	133.86	134.62
Dueling DQN	-95.49	24.32	170.59	169.48	251.38	225.74
Noisy DQN	-63.77	227.61	165.74	238.50	264.10	248.68

По результатам эксперимента видно, что все модели, кроме варианта с Prioritized Replay, смогли достичь значений средней награды выше 200. Базовая DQN-модель перешла в область положительных значений после 250–300 эпизодов: на 300-м эпизоде средняя награда составила 52.45, а к 500-му эпизоду выросла до 234.03. К концу обучения базовая модель показала итоговое значение 265.54, что является наибольшим результатом на 1000-м эпизоде среди всех рассмотренных вариантов.

Модель DQN + Prioritized Replay показала более медленную динамику. До 300-го эпизода средняя награда оставалась отрицательной и составила -82.52. На 500-м эпизоде значение стало положительным и достигло 11.54, а максимальное значение по контрольным точкам было получено на 800-м эпизоде и составило 181.30. На 1000-м эпизоде результат составил 134.62, то есть данная модификация не достигла порога 200 при выбранных параметрах обучения.

Модель Dueling DQN показала более выраженный рост на поздних этапах обучения. На 500-м эпизоде средняя награда составила 170.59, на 600-м эпизоде - 213.21, а на 900-м эпизоде достигла 251.38. Итоговое значение на 1000-м эпизоде составило 225.74. Это показывает, что разделение оценки состояния и преимущества действий позволило модели выйти на устойчивые положительные значения, однако итоговый результат оказался ниже, чем у базовой DQN и Noisy DQN.

Модель Noisy DQN продемонстрировала наиболее быстрый выход к значениям выше 200. Уже на 300-м эпизоде средняя награда составила 227.61, тогда как базовая DQN на этом этапе имела значение 52.45, а Dueling DQN - 24.32. На 850-м эпизоде Noisy DQN достигла значения 278.53, что является наибольшим зафиксированным значением среди всех моделей в данном эксперименте. На 1000-м эпизоде результат составил 248.68.

Таким образом, в среде LunarLander-v3 наибольшее итоговое значение на 1000-м эпизоде показала Base DQN со средней наградой 265.54. Наибольшее

промежуточное значение среди всех запусков было получено у Noisy DQN на 850-м эпизоде и составило 278.53. Наиболее быстрый переход через уровень 200 также показала Noisy DQN, достигнув значения 227.61 уже на 300-м эпизоде.

Эксперимент 2. Сравнение модификаций DQN в среде MountainCar-v0

Во втором эксперименте те же четыре варианта DQN-модели сравнивались в среде MountainCar-v0. Обучение выполнялось в течение 1000 эпизодов. Для данной среды характерна отрицательная награда за каждый шаг, поэтому рост качества выражается в увеличении средней награды от -200 к менее отрицательным значениям.




Рисунок 1 - Сравнение модификаций DQN в среде LunarLander-v3

Модель	Эпоха 100	Эпоха 300	Эпоха 500	Эпоха 700	Эпоха 900	Эпоха 1000
Base DQN	-200.00	-178.88	-156.88	-144.62	-109.68	-127.50
DQN + Prioritized Replay	-199.66	-188.88	-153.72	-128.62	-106.78	-115.10
Dueling DQN	-200.00	-150.24	-157.88	-131.94	-135.30	-107.98
Noisy DQN	-188.26	-145.88	-134.14	-134.34	-119.10	-107.66

В среде MountainCar-v0 наибольшее итоговое значение на 1000-м эпизоде показала Noisy DQN со средней наградой -107.66. Очень близкий результат показала Dueling DQN со значением -107.98. Модель с Prioritized Replay достигла наилучшего промежуточного значения -106.78 на 900-м эпизоде, но к 1000-му эпизоду снизилась до -115.10. Базовая DQN показала итоговое значение -127.50, что ниже результатов модифицированных моделей.

Вывод.

В рамках выполнения проекта были реализованы базовый алгоритм DQN и его модификации: Prioritized Replay, Dueling Network и Noisy Net. Эксперименты проводились в средах LunarLander-v3 и MountainCar-v0 в течение 1000 эпизодов. По итоговым значениям средней реальной награды были получены следующие результаты обучения:

Модификация	LunarLander-v3	MountainCar-v0
Base DQN	265.54	-127.50
Prioritized Replay	134.62	-115.10
Dueling Network	225.74	-107.98
Noisy Net	248.68	-107.66

Наиболее универсальной модификацией в проведённых экспериментах можно считать Noisy Net, так как она показала высокий результат в LunarLander-v3 и лучший итоговый результат в MountainCar-v0. Dueling Network также обеспечила устойчивый прирост качества, особенно в MountainCar-v0. Модификация Prioritized Replay в данных настройках не дала стабильного преимущества: в LunarLander-v3 её итоговый результат оказался существенно ниже остальных вариантов, хотя в MountainCar-v0 она превысила базовую DQN.